

Tipología y ciclo de vida de los datos

Práctica 1

[Fernando Rodríguez López]



08/04/2018

Título del dataset

Diputados del Congreso de los diputados (Cámara Baja) de España (CBE)

Subtítulo del dataset

Recopilación de todos los diputados del Congreso de los diputados (Cámara Baja) de España desde su constitución en 1977.

Imagen




Figure 1: Cámara Baja Española

Contexto

En la actual situación política Española donde entre los años 2011 al 2019 se producido 3 legislaturas, se hace necesario recopilar la información de las distintas constituciones de la cámara baja.

Los medios de comunicación informan sobre la distribución de dicha cámara en la última legislatura comparada con las encuestas.

Pero que mejor forma de contrastarla o poder ayudar a estructurar estos datos para futuros análisis, que automatizar la recopilación de información directamente de la página web del [Congreso de los diputados](#). De esta forma se puede facilitar la utilización de esta información por herramientas de terceros.

La página actual del Congreso de los diputados presenta la información únicamente en formato web y no existe ningún mecanismo de descarga.

Contenido

El programa desarrollado permite la recopilación de los datos de todos los miembros de la cámara baja según el criterio del número de legislatura.

En el programa permite seleccionar una única legislatura o un rango de ellas. Esto permite una recopilación de todas ellas o si se ha investido una nuevo recopilar la información de la nueva.

Se ha implementado además un sistema de caché para evitar tener que repetir el proceso completo por causas de caída de la web o fallo en la conexión.

Además de la creación final de un fichero csv se permite en el formato json para facilitar el almacenamiento en alguna base de datos NOSQL o la implementación futura de un caché en este tipo de base de datos.

La información parte del apartado [diputados](#) de la página oficial del congreso de los diputados.

Esta página tiene un desplegable para seleccionar la legislatura.

Es por ello que además la herramienta permite obtener dicho listado por pantalla para evitar el acceso cuando se requiera la información.

Desde esta página inicial se va recorriendo el listado de cada una de las legislaturas y accediendo a la página de detalle de cada uno de los diputados para obtener la información propia de cada uno.

Esta información se tendrá que recopilar de nuevo cada vez que se produzcan unas nuevas elecciones en España

Descripción del Dataset

Cada informe que se obtiene consta de los siguientes atributos

Atributo	Descripción
name	Nombre del Diputado
mail	Correo electrónico personal
party.name	Partido político por el que ha obtenido el escaño
party.url	Link a la página web del partido político
province	Provincia a la que representa en la cámara
web	Página web personal del diputado
url	Página web de donde se ha recopilado la información

Atributo	Descripción
social.facebook	Página de perfil de facebook
social.linkedin	Página de perfil de LinkedIn
social.twitter	Página de perfil de Twitter
birthday.day	día de nacimiento
birthday.month	mes de nacimiento
birthday.year	año de nacimiento
dates.entry_date	Fecha de alta como diputado
dates.leaving_date	Fecha de baja como diputado
legislature.start_year	Año de comienzo de la legislatura
legislature.end_year	Año de finalización de la legislatura
legislature.number	Número de la legislatura
legislature.raw_name	Nombre de la legislatura completo
legislature.roman_number	Número romano de la legislatura

Los datos han sido recogidos en bruto y por lo tanto pueden tener inconsistencias.

Agradecimientos

Agradecimientos a la [página oficial de Congreso de los Diputados de España](#) por mantener la información de todos los diputados.

Sin este mantenimiento no podríamos haber realizado este trabajo.

A [Stackoverflow](#) por esta base de datos de conocimiento que nos ayuda a solventar diariamente a los pequeños y grandes dudas que surgen durante la programación.

A [regex101](#) por hacer más sencillo la creación de expresiones regulares.

Inspiración

Las noticias tanto vía web, televisión o prensa escrita que informan diariamente de la situación política.

Especialmente en época electoral donde aparece la información y gráficos comparando la situación actual del Congreso con las encuestas generadas.

Licencia

Este programa se ha desarrollado bajo la licencia **CC BY-NC-SA 4.0 License**. Permitiendo la copia, distribución y el uso del dataset siempre y cuando se reconozca y cite al autor, con fines no comerciales.

También se permite que otros puedan contribuir creando trabajos derivados siempre y cuando lo hagan bajo una licencia idéntica.

Usted es libre de:

- **Compartir** — copiar y redistribuir el material en cualquier medio o formato
- **Adaptar** — remezclar, transformar y crear a partir del material El licenciador no puede revocar estas libertades mientras cumpla con los términos de la licencia.

Bajo las condiciones siguientes:

- **Reconocimiento** — Debe reconocer adecuadamente la autoría, proporcionar un enlace a la licencia e indicar si se han realizado cambios. Puede hacerlo de cualquier manera razonable, pero no de una manera que sugiera que tiene el apoyo del licenciador o lo recibe por el uso que hace.
- **NoComercial** — No puede utilizar el material para una finalidad comercial.

Código

El código se encuentra disponible en

<https://github.com/tanakafer/camaraBaja>

Dataset

Se han generado un único dataset en dos formatos csv y json disponibles en le directory output de github

<https://github.com/tanakafer/camaraBaja>

Estructura de Ficheros y Carpetas

cbe_crawler.py: Programa ejecutable. Para más ayuda

```
python cbe_crawler.py -h
```

output: Carpeta donde se almacena el resultado de la ejecución

- **congreso.csv:** fichero de salida en formato csv
- **congreso.json:** fichero de salida en formato json

pandoc.sh: Fichero ejecutable para convertir Markdown a pdf. Necesario instalación de docker

practica1.pdf: Documento de respuestas pdf

README.md: Fichero origen del documento de respuestas

cache: Carpeta de almacenamiento del caché

images: Carpeta de almacenamiento de las imágenes auxiliares

uoc.tex: Plantilla de conversión Markdown a pdf y docx

Contribuciones

Contribuciones	Firma
Investigación previa	FRL
Redacción de las respuestas	FRL
Desarrollo código	FRL